ENSA
ÉCOLE NATIONALE DES SCIENCES APPLIQUÉES
KHOURIBGA

RAPPORT PROJET GPI : MAINTENANCE PRÉDICTIVE

2022 - 2023

Réalisé Par :

- Matouk Afaf
- Guerrab Mouna
- El Jaouhari Mohamed
- El Amrani Ilyas

Encadré Par :

Pr. ER-RATBY Mohamed

Sommaire :

1. Introduction :

La maintenance prédictive utilise un ensemble des méthodes pour prédire quand une machine ou un équipement est susceptible de tomber en panne, et planifier de manière proactive la maintenance pour éviter cette panne. Cette approche proactive de la maintenance permet de réduire les temps d'arrêt, d'augmenter l'efficacité et de prolonger la durée de vie de l'équipement.

Traditionnellement, la maintenance était effectuée selon des calendriers établis ou lorsque l'équipement présentait des signes de défaillance. Cette approche passive peut entraîner des temps d'arrêt inutiles, une augmentation des coûts et une perte de productivité. La maintenance prédictive, quant à elle, utilise les données collectées à partir de capteurs, de journaux d'appareils et d'autres sources pour identifier les signes avant-coureurs d'une défaillance de l'appareil et prévoir quand une maintenance est nécessaire.

La maintenance prédictive peut être appliquée à une variété d'industries, y compris la fabrication, le transport, l'énergie et la santé, et gagne en popularité avec l'avènement de l'internet des objets (IoT) et la disponibilité des outils d'analyse de données volumineuses (Big data analytics).

2. Science des données & maintenance predictive :

La science des données joue un rôle clé dans la maintenance prédictive. La maintenance prédictive repose sur l'analyse de grandes quantités de données provenant de diverses sources telles que les capteurs de périphérique, les journaux de maintenance et les données de performances historiques. Les scientifiques des données peuvent analyser ces données à l'aide d'algorithmes d'apprentissage automatique et de techniques analytiques avancées pour identifier les modèles et les anomalies qui peuvent indiquer une défaillance imminente de l'équipement.

L'application de la science des données à la maintenance prédictive aide les organisations à mieux comprendre l'état des équipements, à identifier les signes avant-coureurs de problèmes potentiels et à déterminer à quel moment la maintenance doit être effectuée pour éviter les pannes d'équipement. La science des données aide également à optimiser les calendriers de maintenance et à effectuer la maintenance au bon moment pour minimiser les temps d'arrêt et maximiser l'efficacité.

3. Jeu des données utilisées :

Notre jeu de donnée se manifeste en une entreprise qui dispose un appareil qui envoie quotidiennement des lectures de capteurs. Elle souhaite développer une solution de maintenance prédictive qui identifie de manière proactive le moment où la maintenance doit être effectuée. Cette approche promet des économies par rapport à la maintenance préventive régulière ou basée sur le temps. En effet, la tâche ne s'exécutera que si elle est légitime.

Nos données sont disponible sous forme d'un fichier Excel contenant la date de chaque enregistrement, avec des mesures captées lors d'exécution de tache, accompagné par une colonne présentant si la machine a échoué ou non pendant la journée.

à propos des dates, nos enregistrement sont propres à l'année 2015, à partir de 01/01 jusqu'à 01/12.

4. Implémentation :

Pour pouvoir implémenter nos idées et construire ce système, nous allons découper notre projet en 5 étapes :

- Analyser et évaluer notre jeu de données
- Développer les fonctionnalités nécessaires pour le fonctionnement du système.
- Développer le modèle final.
- Calculer les indicateurs de performance.

Le but de cette partie est d'expliquer comment implémenter informatiquement les idées discutées précédemment, ainsi qu'expliquer les solutions proposées pour faire face aux différentes contraintes du problème en terms de données, de calcule et des technologies utilisées.

La suite est l'explication du notebook joint à ce document (annex A) , nous présenterons des commentaires et des explications tout au long de la lecture des différentes sections de la réalisation.

4. Implémentation :

4.1 Analyse et évaluation du jeu de données:

La première étape consiste à analyser et évaluer notre jeu de données pour savoir quels variables de décisions qu'on peut utiliser, cette partie concerne les sections 1 jusqu'à 4 (Data Transformation).
Nos données sont de forme tabulaire avec les colonnes "date", "device","failure","metric1", ..., "metric9", la colonne "date" décrit la date avec le format standard "JJ/MM/AAAA", la colonne "device" est le nom de l'appareil ou la machine dont on mesure les différents metrics de 1 à 9, finalement la colonne "failure" est une variable binaire prenant la valeur 1 s'il y avait une panne ce jour ou non.
La mesure des métriques est supposée quasi-constante durant toute la journée.
Les conclusions principales de notre analyse sont :

- La rareté des pannes : On a 106 enregistrement de pannes, contre 124388 enregistrement sans panne.
- Le graph du code [142] montre clairement que le nombre d'enregistrements sur les machines devient de moins en moins fréquent après chaque mois, confirmant les données numériques du tableau [141].

- Le code [145] montre la diminution de nombre d'enregistrements sur les machines le plus on avance dans l'axe des temps.
- Le code [144] montre que nos données sont daté entre le 1 Janvier 2015 et le 2 Novembre 2015
- Le code [155] permet de supprimer la colonne "metric8" puisque elle a des valeurs égaux à ceux de la colonne "metric7".
- Nous avons pu rendre nos données sous une forme plus intéressante pour un modèle de machine learning en exposant de nouvelles colonnes qu'on peut utiliser dans le but de prédire nos pannes comme la colonne "ActiveDays" qui permet de calculer en cumulation combien de jours la machine était elle active, "week_day" et "month" pour numérisé la date vue que le type date est difficile à traiter par un algorithme de machine learning sans transformation, et la colonne "failure_before", pour savoir si dans l'enregistrement actuelle la machine a-t-elle déjà tombé en panne au moins une fois avant ou non.

Pour la suite, nous allons développer un pipeline, qui est un algorithme simple, permettant de mettre dans la forme finale de cette partie nos données en entré.

4. Implémentation :

4.2 Outils nécessaires au fonctionnement de système:

Le pipeline est un outil qui permet d'extraire et transformer les données pour les mettre en une forme souhaité, qui rend les données prêt à la consommation par un algorithme quelconque, de machine learning dans notre cas.
Dans cette partie (5-6), le pipeline est développé et tester avec un algorithme de machine learning simple 'KNN', qu'on va expliquer par la suite.
Dans la première partie nous nous inspirons des traitement effectuées dans la première partie pour construire la fonction pipeline, qui prend en paramètre la base de données utilisée, l'enregistrement à transformer sous la forme d'une liste de valeurs, et un objet 'scalar' qui permet de mettre à la même échelle les métriques de l'enregistrement avec ceux de la base.
La totalité des procedures effectuées est expliquée en commentaires sur le code.
Pour la deuxième partie, nous préparons nos données pour tester notre pipeline, nous construisons à l'occasion un modèle de machine learning appelé KNN (Les K voisins les plus proches). Après le test et l'entraînement de notre modèle nous obtenons un score d'environ 97%, par suite, nous utilisons le pipeline pour transformer un enregistrement et nous effectuons la prédiction avec le modèle entraîné qui prédit 0, c'est à dire pas de panne.

4. Implémentation :

4.3 Synthétisation des données et création du modèle final:

Pour résoudre le problème de non balance de notre base de données, et pour avoir une situation dans laquelle la maintenance prédictive aura un effet remarquable, nous allons synthétiser une base de données en se basant sur la base de données actuelle, avec une distribution plus adopté pour engendrer plus de pannes, nous concentrons aussi sur un seul type de machines, qui est le type"S1F0" d'après le code [177]. On synthétise dans un premier lieux les données de l'année 2015, on entraîne, de la même manière qu'avant, le modèle KNN sur ces données (code [232]), par la suite, nous générons une dataset pour l'année 2016 pour la validation de notre modèle, sur laquelle nous effectuant nos études. Les codes [235] et [236] sont utilisés pour prédire avec notre modèle les pannes et enregistrer les données sous format CSV, les résultats sont regroupées dans un tableau avec les colonnes "month", "failure" : C'est le nombre de pannes prédites et "realFail" est le nombre des pannes réels qui vont se produire si on effectue pas de maintenance prédictive. Ces résultats seront utilisés par la suite dans le calcule des indicateurs de performance.

4. Implémentation :

4.4 Calcul des KPIs:

Pour calculer les indicateurs de performance, on se base sur le tableau récupéré dans l'étape précedante et on effectue le calcule des KPIs dans le cas ou la maintenance prédictive est effectué, et le cas ou elle n'est pas effectué.
L'annexe B comprend l'implémentation et l'exécution de cette algorithme, bien expliqué avec des commentaire.
A l'issue de cette partie, nous disposons d'un fichier "CSV", de forme tabulaire, à utiliser pour créer notre tableau de bord.

5. Visualisation des résultats:

Question analytique :

Notre Visualisation permet de répondre à cet ensemble des questions dans le cas de la prediction de pannes et de sans prediction de pannes :

1-quel est l'evolution des realFail et failure durant chaque mois ?
2-quel est la valeur de la productivité durant chaque mois?
3-quel est l'evolution de mtbf et la disponibilité materiel pendant chaque mois ?
4-quel est l'evolution de mttr et la disponibilité materiel durant chaque mois ?
5-l'evolution de mtbf et mtrr durant chaque mois ?
6-quel est le temps net pour chaque realFail?
7-quel est le temps brut pour chaque realFail?

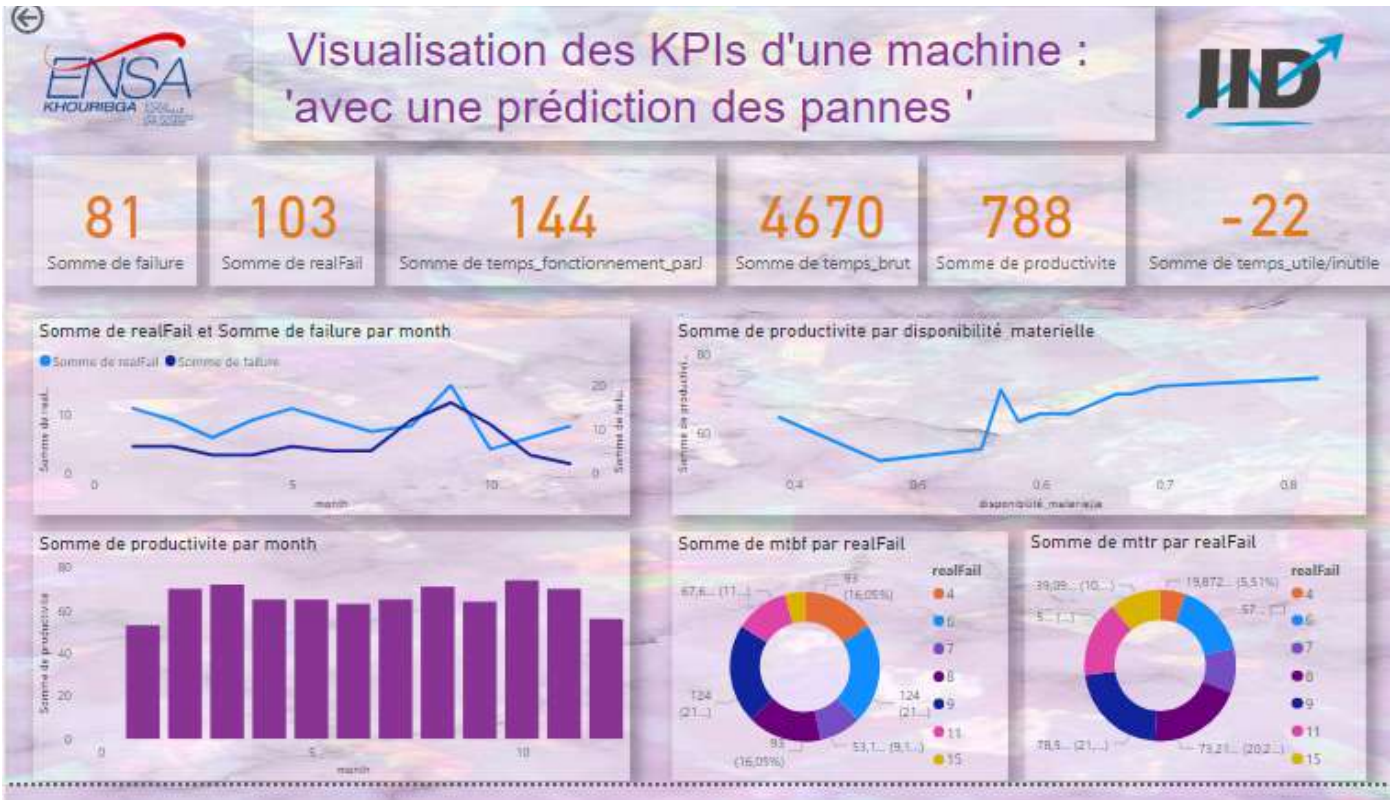
Visualisation des KPIs d'une machine :
'avec une prédiction des pannes '
81
Somme de failure
103
Somme de realFail
144
Somme de temps_fonctionnement_parJ
4670
Somme de temps_brut
788
Somme de productivite
-22
Somme de temps_utile/inutile
Somme de realFail et Somme de failure par month
Somme de productivite par disponibilité_materielle
Somme de productivite par month
Somme de mtbf par realFail
Somme de mttr par realFail


Somme de temps_brut par month
Somme de mtbf et Somme de disponibilité_materielle par month
Somme de mttr et Somme de disponibilité_materielle par month
Somme de mttr et Somme de mtbf par month
Somme de temps_brut et Somme de temps_net par realFail

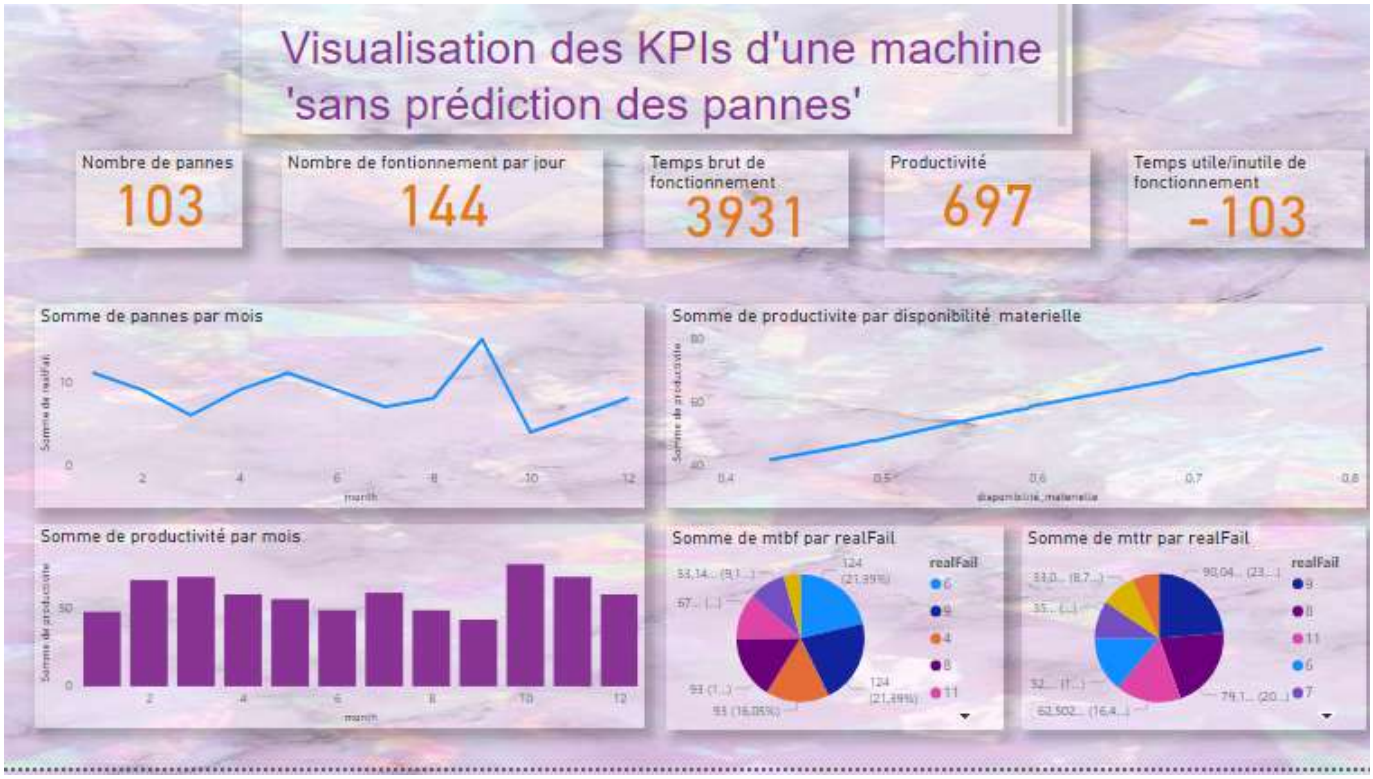
Visualisation des KPIs d'une machine 'sans prédiction des pannes'
Nombre de pannes
103
Nombre de fontionnement par jour
144
Temps brut de fonctionnement
3931
Productivité
697
Temps utile/inutile de fonctionnement
-103
Somme de pannes par mois
Somme de productivite par disponibilité_materielle
Somme de productivité par mois
Somme de mtbf par realFail
Somme de mttr par realFail
realFail


Somme de temps brut de fonctionnement par mois
month
Somme de mtbf et Somme de disponibilité_materielle par mois
Somme de mtbf
Somme de disponibilité_materielle
month
Somme de mttr et Somme de disponibilité_materielle par mois
Somme de mttr
Somme de disponibilité_materielle
month
Somme de mttr et Somme de mtbf par mos
Somme de mttr
Somme de mtbf
month
Somme de temps brut et Somme de temps net de fonctionnement par pannes
Somme de temps_brut
Somme de temps_net
realFail

6. Vision :

Ce projet est le premier pas pour la construction de tout un système, qui sera capable d'apprendre et s'adapter au plan de production et de maintenance de l'entreprise, un système plus complexe qui set de support aux responsables pour la prise des décisions et la planification des activités de maintenance et de la production.
Dans cette partie nous allons décrire une possibilité d'amélioration du projet et le processus avec lequel il peut être appliqué dans le domaine industriel réellement.

Le but de ce système et d'utiliser les sciences de données et l'informatique décisionnelle pour aider les responsables à décider sur les plans de maintenance prédictive et préventive au but d'améliorer la productivité.
Son mode de fonctionnement est constituer généralement de :

- Récolte des données : à l'aide des capteurs sur chaque machine, des rapports quotidiens et les contrôles effectués.
- Stockage et traitement des données: Au but de nettoyage et mise en forme et adaptation pour le modèle de machine learning (fait par le pipeline développé précédemment par exemple).

6. Vision :

- La prédiction : à l'aide du modèle de machine learning des pannes, et la réalisation des plans de maintenance.
- L'établissement des indicateurs de performance provisoires : en se basant sur les prédictions.
- Evaluation des résultats des prédictions et leurs effets: En mettons à jours le tableau de bords et les rapports.
- Entraînement du modèle de machine learning sur les résultats réels.

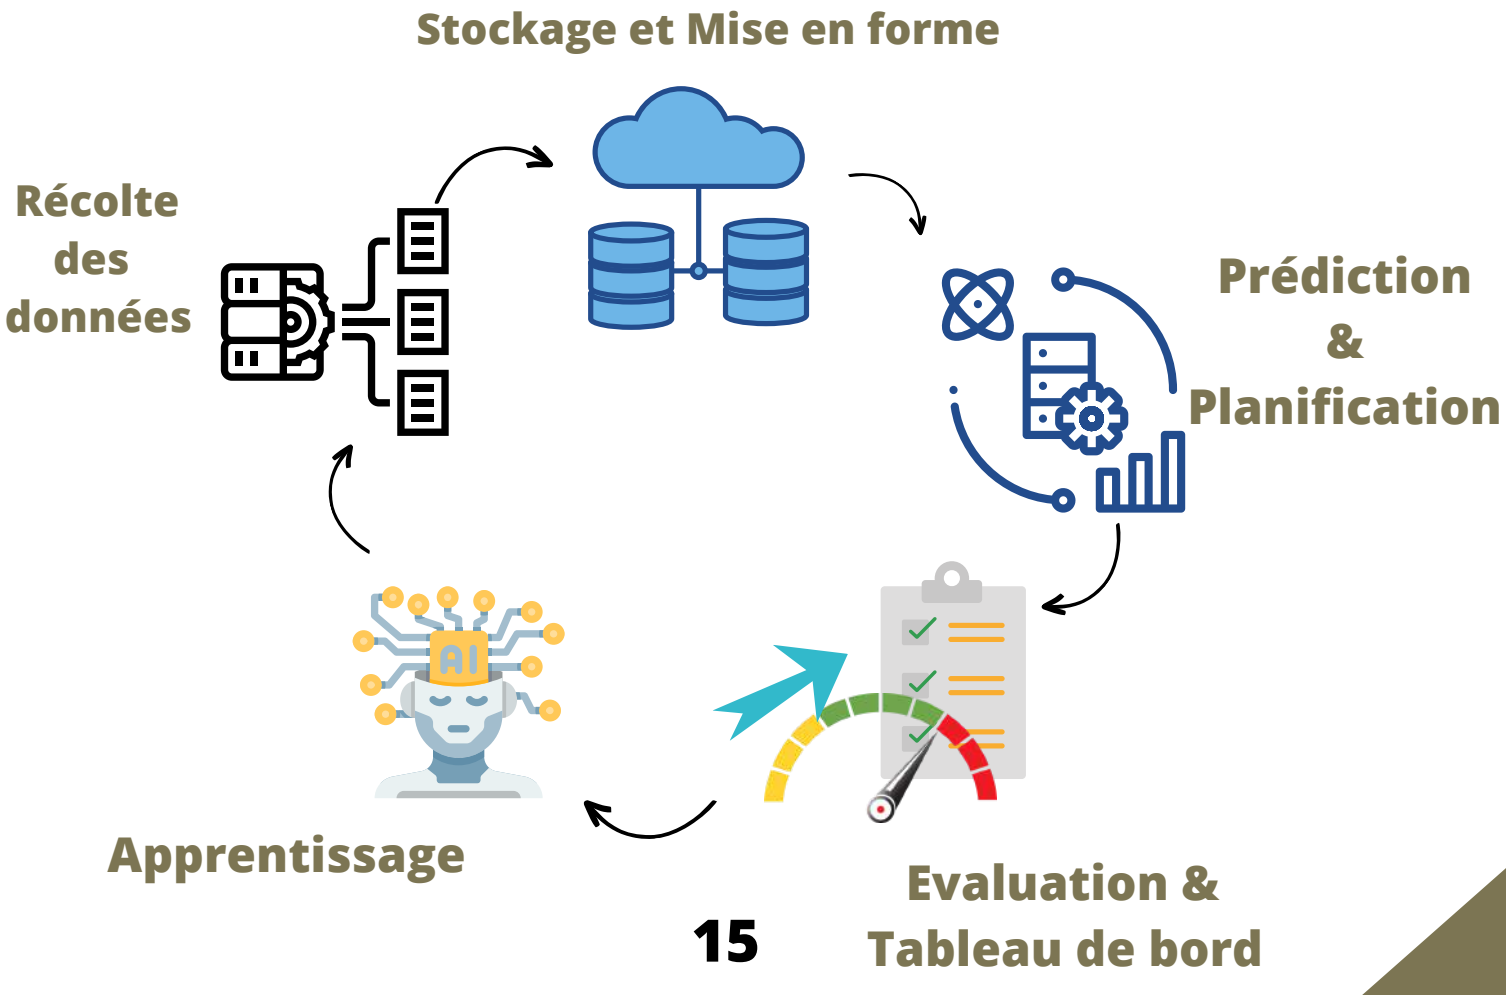

7. Conclusion :

La maintenance prédictive est devenu dernièrement une des piliers majeurs pour optimiser la maintenance de l'environnement industriel comme le cas des machines étudiée dans notre projet.

En la fusionnant avec la science des données, l'optimisation devient plus efficiente et plus économique à l'aide des outils mathématiques et informatiques avancées.

Annex A : Préparation des données et création du modèle

device-failure-final-notebook

May 16, 2023

1 Implémentation :

Réalisé par Ilyas El Amrani, Mohamed El Jaouhari, Afaf Matouk & Mouna Guerrab. Dans cette partie, nous allons chargé nos données, les analyser , les transformer pour pouvoir construire notre modèle, par la suite nous allons utiliser les prédiction de notre modèle pour générer nos KPIs, qui seront affichés par la suite à l'aide de MS Power BI.

[136]:
```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
```

2 Chargement des données

[137]:
```
df = pd.read_csv('predictive_maintenance_dataset.csv')
df.head()
```

[137]:

	date	device	failure	metric1	metric2	metric3	metric4	metric5	\
0	1/1/2015	S1F01085	0	215630672	55	0	52	6	
1	1/1/2015	S1F0166B	0	61370680	0	3	0	6	
2	1/1/2015	S1F01E6Y	0	173295968	0	0	0	12	
3	1/1/2015	S1F01JE0	0	79694024	0	0	0	6	
4	1/1/2015	S1F01R2B	0	135970480	0	0	0	15	

	metric6	metric7	metric8	metric9
0	407438	0	0	7
1	403174	0	0	0
2	237394	0	0	0
3	410186	0	0	0
4	313173	0	0	3

[138]:
```
import pandas_profiling
pandas_profiling.ProfileReport(df)
```

```
Summarize dataset:   0%|          | 0/5 [00:00<?, ?it/s]
Generate report structure:   0%|          | 0/1 [00:00<?, ?it/s]
```

```
Render HTML:   0%|          | 0/1 [00:00<?, ?it/s]
```

```
<IPython.core.display.HTML object>
```

[138]:

[139]:
```
df.failure.value_counts()
```

[139]:
```
0    124388
1       106
Name: failure, dtype: int64
```

Donc on dispose de 124494 enregistrement, dont 106 représentent une panne.

3 Data Engineering

[140]:
```
df.date = pd.to_datetime(df.date)

#Création de la colonne activedays pour pouvoir mesurer de combien de jours la machine est elle active durant cette année.
df['activedays']=df.date-df.date[0]

#Création de la colonne 'month', le mois.
df['month']=df['date'].dt.month
#Création de la colonne 'week_day', le jour de la semaine (0 est Dimanche)
df['week_day']=df.date.dt.weekday
df['week_day'].replace(0,7,inplace=True)
df.head()
```

[140]:

	date	device	failure	metric1	metric2	metric3	metric4	metric5	metric6	metric7	metric8	metric9	activedays	month	week_day
0	2015-01-01	S1F01085	0	215630672	55	0	52	6	407438	0	0	7	0 days	1	3
1	2015-01-01	S1F0166B	0	61370680	0	3	0	6	403174	0	0	0	0 days	1	3
2	2015-01-01	S1F01E6Y	0	173295968	0	0	0	12	237394	0	0	0	0 days	1	3
3	2015-01-01	S1F01JE0	0	79694024	0	0	0	6	410186	0	0	0	0 days	1	3
4	2015-01-01	S1F01R2B	0	135970480	0	0	0	15	313173	0	0	3	0 days	1	3

[141]:
```
#Données par mois
df.groupby('month').agg({'device':lambda x: x.nunique()})
```

[141]:

month	device
1	1164
2	726
3	685
4	491
5	424
6	353
7	346
8	334
9	184
10	146
11	31

On remarque que la quantité des données diminue d'un mois à l'autre d'une manière très rapide.

[142]:
```
#machines par mois
df.groupby('month').agg({'device':lambda x: x.nunique()}).plot()
plt.show()
```

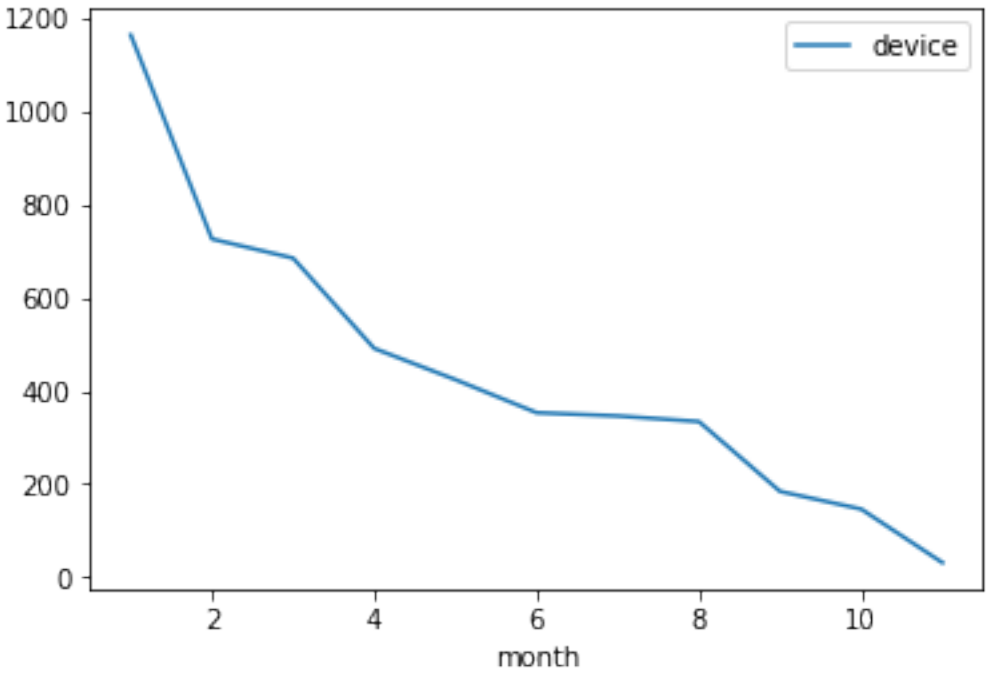

La même remarque sur le nombre des machines, qui diminue d'un mois à l'autre.

[143]:
```
#Nombre de pannes et de fonctionnement normal par mois
ax = sns.countplot(x="month", hue="failure", data=df)
plt.show()
```

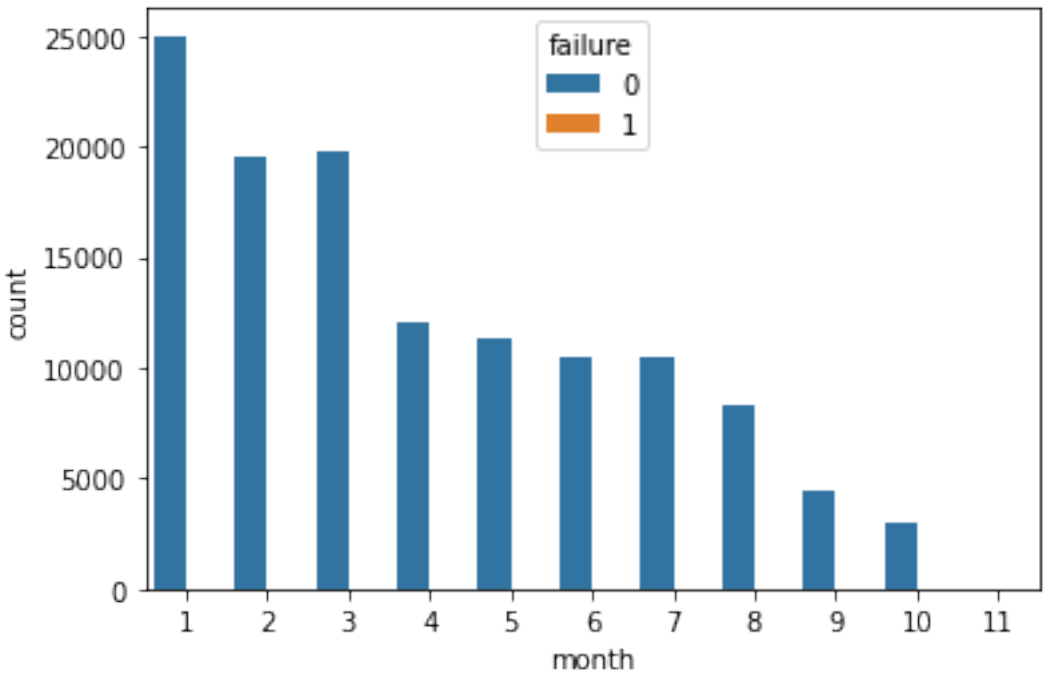

[144]:
```
#Date maxmiale et minimale
max(df.date), min(df.date)
```

[144]: (Timestamp('2015-11-02 00:00:00'), Timestamp('2015-01-01 00:00:00'))

[145]:
```
#Nombre de machines par journées d'activités
df.groupby('activedays')['device'].count().plot()
plt.show()
```

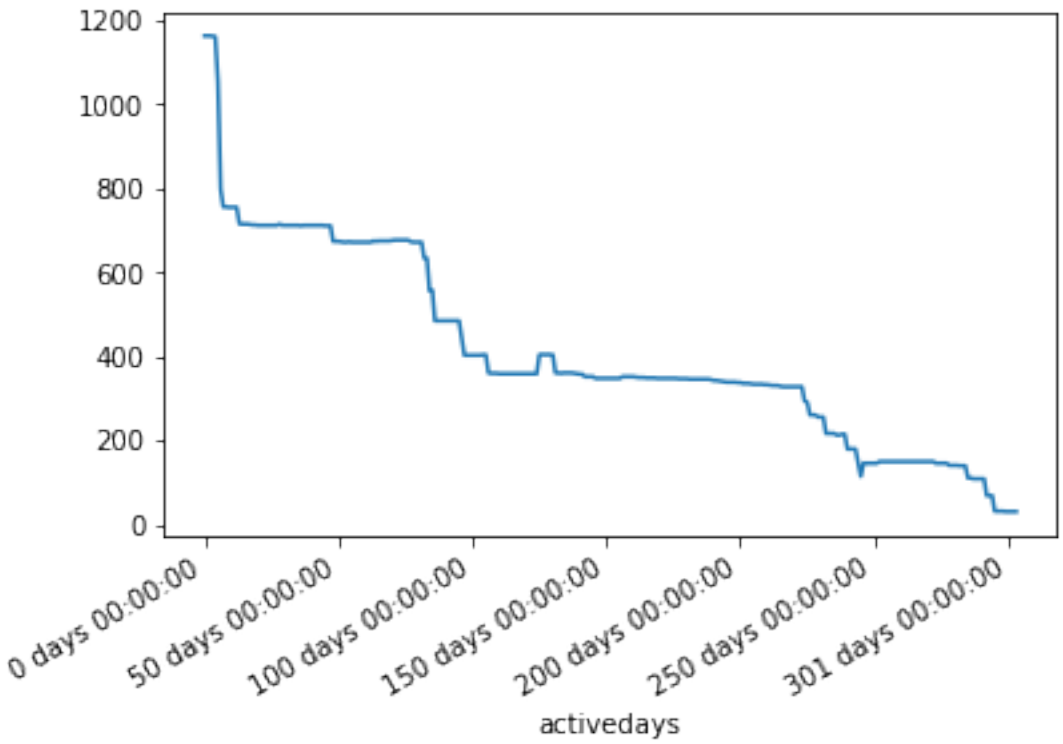

On déduit qu'un nombre très grand de machines ne diposent pas de donnés plus que de 50 jours.

[146]:
```
#Nombre de fonctionnement normale vs pannes par jour de semaine
ax = sns.countplot(x='week_day',hue='failure',data=df)
plt.show()
```

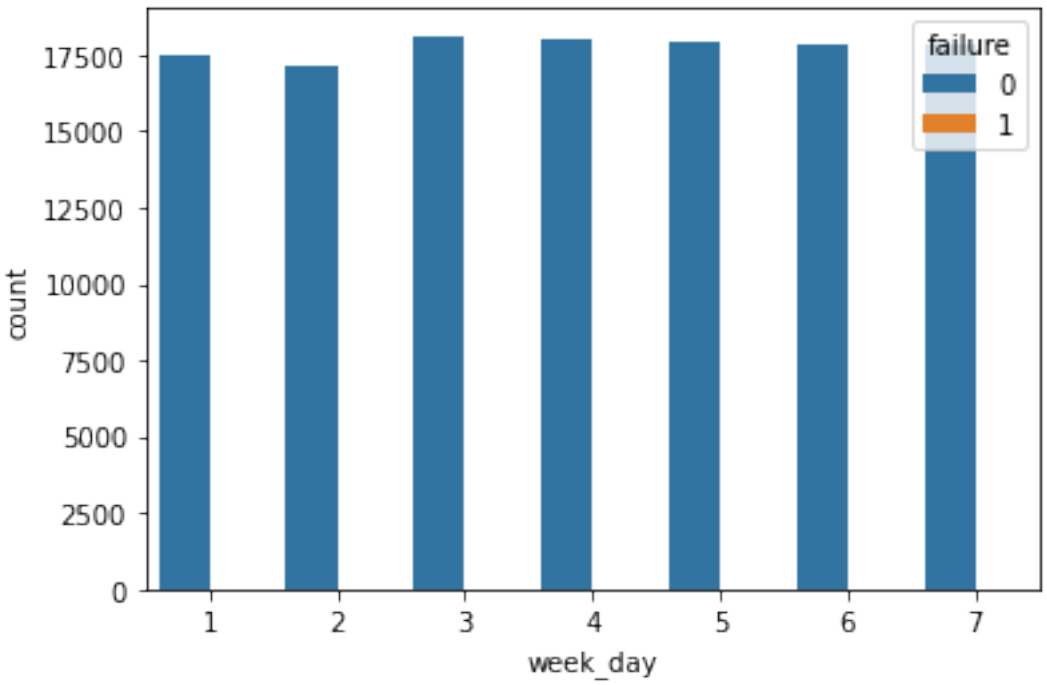

Le nombre de pannes est relativement très bas.

[147]:
```
df_date = df.groupby('device').agg({'date':max})
df_date.date.to_dict()
#Création de la date maximale, c'est à dire la dernière date dont laquelle
df['max_date']=df.device.map(df_date.date.to_dict())
df.head()
```

[147]:

	date	device	failure	metric1	metric2	metric3	metric4	metric5	metric6	metric7	metric8	metric9	activedays	month	week_day	max_date
0	2015-01-01	S1F01085	0	215630672	55	0	52	6	407438	0	0	7	0 days	1	3	2015-01-06
1	2015-01-01	S1F0166B	0	61370680	0	3	0	6	403174	0	0	0	0 days	1	3	2015-01-06
2	2015-01-01	S1F01E6Y	0	173295968	0	0	0	12	237394	0	0	0	0 days	1	3	
3	2015-01-01	S1F01JE0	0	79694024	0	0	0	6	410186	0	0	0	0 days	1	3	
4	2015-01-01	S1F01R2B	0	135970480	0	0	0	15	313173	0	0	3	0 days	1	3	

```
2 2015-02-17
3 2015-01-06
4 2015-08-24
```

[148]:
```
#Date maximale d'enregistrement de données par machine
df1 = df.groupby('device').agg({'date':max})
df1.head()
```

[148]:
```
                date
device
S1F01085 2015-01-06
S1F013BB 2015-05-11
S1F0166B 2015-01-06
S1F01E6Y 2015-02-17
S1F01JE0 2015-01-06
```

[149]:
```
# Nous allons maintenant essayer de créer une variable qui mesure si notre␣
 ↪machine a tombé en panne précédemment ou pas
df1=df1.reset_index()

df=df.reset_index(drop=True)

df2= pd.merge(df1,df,how='left',on=['device','date'])

df2.head()
```

[149]:
```
     device       date  failure    metric1  metric2  metric3  metric4  \
0  S1F01085 2015-01-06        0  128832128       56        0       52
1  S1F013BB 2015-05-11        0  115676688        0        0        0
2  S1F0166B 2015-01-06        0    7441792        0        3        0
3  S1F01E6Y 2015-02-17        0  147350000        0        0        0
4  S1F01JE0 2015-01-06        0  185424928        0        0        0

   metric5  metric6  metric7  metric8  metric9 activedays  month  week_day  \
0        6   409404        0        0        7     5 days      1         1
1        5   689161        0        0        0   130 days      5         7
2        6   404786        0        0        0     5 days      1         1
3       12   259491        0        0        0    47 days      2         1
4        6   412151        0        0        0     5 days      1         1

    max_date
0 2015-01-06
1 2015-05-11
2 2015-01-06
3 2015-02-17
4 2015-01-06
```

[150]:
```
df2['failure_before']=0
df2.head()
```

[150]:

	device	date	failure	metric1	metric2	metric3	metric4	\
0	S1F01085	2015-01-06	0	128832128	56	0	52	
1	S1F013BB	2015-05-11	0	115676688	0	0	0	
2	S1F0166B	2015-01-06	0	7441792	0	3	0	
3	S1F01E6Y	2015-02-17	0	147350000	0	0	0	
4	S1F01JE0	2015-01-06	0	185424928	0	0	0	

	metric5	metric6	metric7	metric8	metric9	activedays	month	week_day	\
0	6	409404	0	0	7	5 days	1	1	
1	5	689161	0	0	0	130 days	5	7	
2	6	404786	0	0	0	5 days	1	1	
3	12	259491	0	0	0	47 days	2	1	
4	6	412151	0	0	0	5 days	1	1	

	max_date	failure_before
0	2015-01-06	0
1	2015-05-11	0
2	2015-01-06	0
3	2015-02-17	0
4	2015-01-06	0

[151]:
```
#On sait, d'après l'analyse précédante que ces machines on eu déjà une panne
df2.loc[df2.device == 'S1F136J0','failure_before'] = 1
df2.loc[df2.device == 'W1F0KCP2','failure_before'] = 1
df2.loc[df2.device == 'W1F0M35B','failure_before'] = 1
df2.loc[df2.device == 'S1F0GPFZ','failure_before'] = 1
df2.loc[df2.device == 'W1F11ZG9','failure_before'] = 1
```

4 Data Transformation

[152]:
```
cat_ftrs = ['metric3','metric4', 'metric5', 'metric7', 'metric9']
for col in cat_ftrs:
    df2[col]=df2[col].astype('object')
```

[153]:
```
#Conversion des activesdays vers le type entier
def str_to_num(str):
    return str.split(' ')[0]
df2.activedays = df2.activedays.astype('str')
df2.activedays=df2.activedays.apply(str_to_num)
df2.activedays = df2.activedays.astype('int')
df2.head()
```

[153]:

	device	date	failure	metric1	metric2	metric3	metric4	metric5	metric6	metric7	metric8	metric9	activedays	month	week_day	max_date	failure_before
0	S1F01085	2015-01-06	0	128832128	56	0	52	6	409404	0	0	7	5	1	1	2015-01-06	0
1	S1F013BB	2015-05-11	0	115676688	0	0	0	5	689161	0	0	0	130	5	7	2015-05-11	0
2	S1F0166B	2015-01-06	0	7441792	0	3	0	6	404786	0	0	0	5	1	1	2015-01-06	0
3	S1F01E6Y	2015-02-17	0	147350000	0	0	0	12	259491	0	0	0	47	2	1	2015-02-17	0
4	S1F01JE0	2015-01-06	0	185424928	0	0	0	6	412151	0	0	0	5	1	1	2015-01-06	0

[154]:
```
# converstion du mois et de jour de la semaine en type catégorique
for col in ['month','week_day']:
    df2[col]=df2[col].astype('object')
```

[155]:
```
# la colonne metric8 est metric7 sont semblables
df2.drop('metric8',axis=1,inplace=True)
```

5 Pipeline

[156]:
```
df_pipeline = df2.copy()
df_pipeline.head()
```

[156]:

	device	date	failure	metric1	metric2	metric3	metric4	metric5	metric6	metric7	metric9	activedays	month	week_day	max_date
0	S1F01085	2015-01-06	0	128832128	56	0	52	6	409404	0	7	5	1	1	2015-01-06
1	S1F013BB	2015-05-11	0	115676688	0	0	0	5	689161	0	0	130	5	7	2015-05-11
2	S1F0166B	2015-01-06	0	7441792	0	3	0	6	404786	0	0	5	1	1	2015-01-06
3	S1F01E6Y	2015-02-17	0	147350000	0	0	0	12	259491	0	0	47	2	1	2015-02-17
4	S1F01JE0	2015-01-06	0	185424928	0	0	0	6	412151	0	0	5	1	1	2015-01-06

```
   failure_before
0               0
1               0
2               0
3               0
4               0
```

[157]:
```
len(['metric1', 'metric2', 'metric3', 'metric4', 'metric5', 'metric6',
       'metric7', 'metric9', 'activedays', 'failure_before','device_S1F0',␣
 ↪'device_S1F1',
       'device_W1F0', 'device_W1F1', 'device_Z1F0', 'device_Z1F1',
       'device_Z1F2', 'month_1' , 'month_2', 'month_3', 'month_4', 'month_5',␣
 ↪'month_6',
       'month_7', 'month_8', 'month_9', 'month_10', 'month_11','week_day_1',␣
 ↪'week_day_2',
       'week_day_3', 'week_day_4', 'week_day_5', 'week_day_6', 'week_day_7'])
```

[157]:
```
35
```

[158]:
```
from datetime import datetime
def pipeline(base,array,scaler):

    # notre vecteur d'entrée
    """
    [date d'aujourd'hui ,device name,
    'metric1', 'metric2', 'metric3', 'metric4', 'metric5', 'metric6',␣
 ↪'metric7', 'metric9']
    """
    # our output array
    length = len(['metric1', 'metric2', 'metric3', 'metric4', 'metric5',␣
 ↪'metric6',
       'metric7', 'metric9', 'activedays', 'failure_before','device_S1F0',␣
 ↪'device_S1F1',
       'device_W1F0', 'device_W1F1', 'device_Z1F0', 'device_Z1F1',
       'device_Z1F2', 'month_1' , 'month_2', 'month_3', 'month_4', 'month_5',␣
 ↪'month_6',
       'month_7', 'month_8', 'month_9', 'month_10', 'month_11','week_day_1',␣
 ↪'week_day_2',
       'week_day_3', 'week_day_4', 'week_day_5', 'week_day_6', 'week_day_7'])

    output_array = [0 for i in range(length)]

    # notre vecteur de sortie
    match array[1][:4] :
        case "S1F0" : output_array[10] = 1
```

```
        case "S1F1" : output_array[11] = 1
        case "W1F0" : output_array[12] = 1
        case "W1F1" : output_array[13] = 1
        case "Z1F0" : output_array[14] = 1
        case "Z1F1" : output_array[15] = 1
        case "Z1F2" : output_array[16] = 1

    # prenons le mois et le jour
    temp = array[0]
    array[0] = datetime.strptime(array[0], "%Y-%m-%d")
    month = array[0].month
    #print(f"month = {month}")
    day = array[0].weekday() +1 # LUNDI = 0 donc on ajoute 1 pour avoir lundi =1
    #print(f"day = {day}")


    # insertion des jours
    match day :
        case 1 : output_array[28] = 1
        case 2 : output_array[29] = 1
        case 3 : output_array[30] = 1
        case 4 : output_array[31] = 1
        case 5 : output_array[32] = 1
        case 6 : output_array[33] = 1
        case 7 : output_array[34] = 1

    # insertions des mois
    match month :
        case 1 : output_array[17] = 1
        case 2 : output_array[18] = 1
        case 3 : output_array[19] = 1
        case 4 : output_array[20] = 1
        case 5 : output_array[21] = 1
        case 6 : output_array[22] = 1
        case 7 : output_array[23] = 1
        case 8 : output_array[24] = 1
        case 9 : output_array[25] = 1
        case 10 : output_array[26] = 1
        case 11 : output_array[27] = 1

    # Trouvons combien de jour la machine était actif
    for i in base.device :
        if array[1] == i:
        # conversion de la colonne des dates en type date
            time = base[base.device == array[1]].date.values
            time = np.datetime_as_string(time, unit='D')[0]
            time = datetime.strptime(time,"%Y-%m-%d")
```

```
            output_array[8] = time.day
            # ajout des jours entre aujourd'hui et mois 10 (en supposant que notre modèle va prédire à partir de 01/10/2015)
            new_days = datetime.strptime(temp, "%Y-%m-%d") - datetime.strptime('2015-10-01', "%Y-%m-%d")
            output_array[8] = output_array[8] + new_days.days
            break


    # on mentionne si la machine a déjà tombé en panne précedement ou non
    failures = base.groupby('device').agg({'failure_before':lambda x: np.sum(x)})
    for i in failures.index :
        if i == array[1] :
            output_array[9] = failures.loc[i].failure_before

    # normalisation des données
    array = np.array(array)
    output_array = np.array(output_array,np.float64)
    val = scaler.transform(array[2:].reshape(1, -1))
    output_array[:8] = val.flatten()

    return output_array.reshape(1, -1)
```

6 Essai de pipeline

[ ]:
```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler() # objet pour normaliser les données
```

[159]:
```
df_train = df2.copy()
```

[160]:
```
num_ftrs=['metric1','metric2','metric3','metric4','metric5','metric6','metric7','metric9']
df_train[num_ftrs]=scaler.fit_transform(df_train[num_ftrs]) # entrainement de l'objet sur les données d'entrainement numérique
df_train.head()
```

[160]:

	device	date	failure	metric1	metric2	metric3	metric4	\
0	S1F01085	2015-01-06	0	0.094795	-0.136309	-0.042339	0.534665	
1	S1F013BB	2015-05-11	0	-0.092146	-0.145660	-0.042339	-0.124295	
2	S1F0166B	2015-01-06	0	-1.630184	-0.145660	-0.038274	-0.124295	
3	S1F01E6Y	2015-02-17	0	0.357937	-0.145660	-0.042339	-0.124295	
4	S1F01JE0	2015-01-06	0	0.898989	-0.145660	-0.042339	-0.124295	

	metric5	metric6	metric7	metric9	activedays	month	week_day	\

```
0 -0.521389  1.333502 -0.101656 -0.047396           5     1        1
1 -0.602290  4.008798 -0.101656 -0.050645         130     5        7
2 -0.521389  1.289341 -0.101656 -0.050645           5     1        1
3 -0.035987 -0.100105 -0.101656 -0.050645          47     2        1
4 -0.521389  1.359772 -0.101656 -0.050645           5     1        1

    max_date  failure_before
0 2015-01-06               0
1 2015-05-11               0
2 2015-01-06               0
3 2015-02-17               0
4 2015-01-06               0
```

[161]:
```
# on supprime les 2 colonne liée à la date
df_train.drop(['date','max_date'],axis=1,inplace=True)
```

[162]:
```
# on dive les machines en 6 catégorie, machine de type : S1F0, S1F1, W1F0 ,␣
 ↪W1F1 , Z1F0 , Z1F1
Id = df_train.device.values.tolist()
Id1 = []
for i in Id:
    i = i[:4]
    Id1.append(i)

df_train.device=Id1
df_train.head()
```

[162]:
```
  device  failure   metric1   metric2   metric3   metric4   metric5   metric6  \
0   S1F0        0  0.094795 -0.136309 -0.042339  0.534665 -0.521389  1.333502
1   S1F0        0 -0.092146 -0.145660 -0.042339 -0.124295 -0.602290  4.008798
2   S1F0        0 -1.630184 -0.145660 -0.038274 -0.124295 -0.521389  1.289341
3   S1F0        0  0.357937 -0.145660 -0.042339 -0.124295 -0.035987 -0.100105
4   S1F0        0  0.898989 -0.145660 -0.042339 -0.124295 -0.521389  1.359772

    metric7   metric9  activedays month week_day  failure_before
0 -0.101656 -0.047396           5     1        1               0
1 -0.101656 -0.050645         130     5        7               0
2 -0.101656 -0.050645           5     1        1               0
3 -0.101656 -0.050645          47     2        1               0
4 -0.101656 -0.050645           5     1        1               0
```

[163]:
```
df_train = pd.get_dummies(df_train) # à fin d'obtenir les mois et le jours␣
 ↪divisées
```

```
C:\Users\pc\AppData\Local\Temp\ipykernel_10212\3739043471.py:1: FutureWarning:
In a future version, the Index constructor will not infer numeric dtypes when
passed object-dtype sequences (matching Series behavior)
```

```
  df_train = pd.get_dummies(df_train)
C:\Users\pc\AppData\Local\Temp\ipykernel_10212\3739043471.py:1: FutureWarning:
In a future version, the Index constructor will not infer numeric dtypes when
passed object-dtype sequences (matching Series behavior)
  df_train = pd.get_dummies(df_train)
```

[164]:
```
df_train.head()
```

[164]:
```
   failure   metric1   metric2   metric3   metric4   metric5   metric6  \
0        0  0.094795 -0.136309 -0.042339  0.534665 -0.521389  1.333502
1        0 -0.092146 -0.145660 -0.042339 -0.124295 -0.602290  4.008798
2        0 -1.630184 -0.145660 -0.038274 -0.124295 -0.521389  1.289341
3        0  0.357937 -0.145660 -0.042339 -0.124295 -0.035987 -0.100105
4        0  0.898989 -0.145660 -0.042339 -0.124295 -0.521389  1.359772

    metric7   metric9  activedays  …  month_9  month_10  month_11  \
0 -0.101656 -0.047396           5  …        0         0         0
1 -0.101656 -0.050645         130  …        0         0         0
2 -0.101656 -0.050645           5  …        0         0         0
3 -0.101656 -0.050645          47  …        0         0         0
4 -0.101656 -0.050645           5  …        0         0         0

   week_day_1  week_day_2  week_day_3  week_day_4  week_day_5  week_day_6  \
0           1           0           0           0           0           0
1           0           0           0           0           0           0
2           1           0           0           0           0           0
3           1           0           0           0           0           0
4           1           0           0           0           0           0

   week_day_7
0           0
1           1
2           0
3           0
4           0

[5 rows x 36 columns]
```

[167]:
```
# Posons notre X comme les entrée, et Y notre sortie
X = df_train.drop('failure',axis=1)
Y = df_train.failure
```

[170]:
```
indexes_train = df_pipeline[df_pipeline.date < "2015-10-01"].index
X.iloc[indexes_train].head()
```

[170]:
```
    metric1   metric2   metric3   metric4   metric5   metric6   metric7  \
0  0.094795 -0.136309 -0.042339  0.534665 -0.521389  1.333502 -0.101656
```

```
1 -0.092146 -0.145660 -0.042339 -0.124295 -0.602290  4.008798 -0.101656
2 -1.630184 -0.145660 -0.038274 -0.124295 -0.521389  1.289341 -0.101656
3  0.357937 -0.145660 -0.042339 -0.124295 -0.035987 -0.100105 -0.101656
4  0.898989 -0.145660 -0.042339 -0.124295 -0.521389  1.359772 -0.101656

    metric9  activedays  failure_before  …  month_9  month_10  month_11  \
0 -0.047396           5               0  …        0         0         0
1 -0.050645         130               0  …        0         0         0
2 -0.050645           5               0  …        0         0         0
3 -0.050645          47               0  …        0         0         0
4 -0.050645           5               0  …        0         0         0

   week_day_1  week_day_2  week_day_3  week_day_4  week_day_5  week_day_6  \
0           1           0           0           0           0           0
1           0           0           0           0           0           0
2           1           0           0           0           0           0
3           1           0           0           0           0           0
4           1           0           0           0           0           0

   week_day_7
0           0
1           1
2           0
3           0
4           0

[5 rows x 35 columns]
```

[171]:
```
indexes_test = df_pipeline[df_pipeline.date >= "2015-10-01"].index
X.iloc[indexes_test].head()
```

[171]:
```
     metric1   metric2   metric3   metric4   metric5   metric6   metric7  \
60 -0.037285 -0.145660 -0.042339 -0.124295 -0.359588  1.431379 -0.101656
61  1.384632 -0.145660 -0.042339 -0.124295 -0.602290  0.882199 -0.101656
72  0.191214  0.400737 -0.042339 -0.048261 -0.359588  1.453268 -0.101656
79  1.183773 -0.145660 -0.042339  0.027773 -0.116887  0.797338 -0.101656
81  0.535810 -0.145660 -0.042339  0.040445 -0.116887  0.738315  0.630489

     metric9  activedays  failure_before  …  month_9  month_10  month_11  \
60 -0.049717         291               0  …        0         1         0
61 -0.050645         286               0  …        0         1         0
72 -0.050645         284               0  …        0         1         0
79 -0.050645         305               0  …        0         0         1
81 -0.050645         305               0  …        0         0         1

    week_day_1  week_day_2  week_day_3  week_day_4  week_day_5  week_day_6  \
60           0           0           0           0           0           0
```

```
61           0           1           0           0           0           0
72           0           0           0           0           0           0
79           0           0           0           0           0           0
81           0           0           0           0           0           0

    week_day_7
60           1
61           0
72           1
79           1
81           1

[5 rows x 35 columns]
```

[172]:
```
# division des données en données d'entraienement, et autre de tests
x_train , y_train , x_test , y_test = X.iloc[indexes_train] , Y.
  ↪iloc[indexes_train] , X.iloc[indexes_test] , Y.iloc[indexes_test]
```

6.0.1 Modèle Machine Learning : K-Nearest Neighbors

[173]:
```
from sklearn.neighbors import KNeighborsClassifier
from sklearn import metrics
```

[174]:
```
knn = KNeighborsClassifier(n_neighbors=5)
knn.fit(x_train, y_train)

y_pred = knn.predict(x_test)

print(f"{metrics.accuracy_score(y_test, y_pred)*100} %")
```

```
97.94520547945206 %
```

6.0.2 partie test du pipeline

[175]:
```
l = ["2015-01-06","S1F01085",128832128,56,0,52,6,409404,0,7]
out = pipeline(df2,l,scaler)
```

```
C:\Users\pc\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.10_qbz5n2kf
ra8p0\LocalCache\local-packages\Python310\site-packages\sklearn\base.py:439:
UserWarning: X does not have valid feature names, but StandardScaler was fitted
with feature names
  warnings.warn(
```

[176]:
```
y_pred = knn.predict(out)
y_pred
```

```
C:\Users\pc\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.10_qbz5n2kf
```

```
ra8p0\LocalCache\local-packages\Python310\site-packages\sklearn\base.py:439:
UserWarning: X does not have valid feature names, but KNeighborsClassifier was
fitted with feature names
  warnings.warn(
```

[176]:
```
array([0], dtype=int64)
```

Construction du modèle de prédiction et son utilisation

D'après ce qu'on a vu dans la phase d'analyse, il est claire que la construction d'un modèle fiable avec ces données sera presque impossible, vu le faible nombre d'occurance des pannes, ainsi qu'il ne sera pas très util pour une tel entreprise, ainsi que les metriques ont un type différent pour chaque type de machines, nous allons construit un modèle qui permet de prédire le nombre de pannes par mois et donc pourvoir faire des maintenances prédictives et préventives, pour le faire nous allons au début générer des données en se basant sur les données précédantes.

Sélectionnons un type de machines précis:

[177]:
```
for device in ['device_S1F0', 'device_S1F1', 'device_W1F0',␣
 ↪'device_W1F1','device_Z1F0', 'device_Z1F1', 'device_Z1F2']:
    print(f'{device} : {df_train[df_train[device]==1].shape}')
```

```
device_S1F0 : (391, 36)
device_S1F1 : (139, 36)
device_W1F0 : (282, 36)
device_W1F1 : (138, 36)
device_Z1F0 : (149, 36)
device_Z1F1 : (67, 36)
device_Z1F2 : (3, 36)
```

On choisi les machines de type S1F0 puisque on dispose de beaucoup de données sur eux, On élemine les colonnes non nécessaires :

[178]:
```
df_train.columns
```

[178]:
```
Index(['failure', 'metric1', 'metric2', 'metric3', 'metric4', 'metric5',
       'metric6', 'metric7', 'metric9', 'activedays', 'failure_before',
       'device_S1F0', 'device_S1F1', 'device_W1F0', 'device_W1F1',
       'device_Z1F0', 'device_Z1F1', 'device_Z1F2', 'month_1', 'month_2',
       'month_3', 'month_4', 'month_5', 'month_6', 'month_7', 'month_8',
       'month_9', 'month_10', 'month_11', 'week_day_1', 'week_day_2',
       'week_day_3', 'week_day_4', 'week_day_5', 'week_day_6', 'week_day_7'],
      dtype='object')
```

[179]:
```
df_train1 = df_train[df_train['device_S1F0']==1].copy()
df_train1.drop(['device_S1F0', 'device_S1F1', 'device_W1F0', 'device_W1F1',
       'device_Z1F0', 'device_Z1F1', 'device_Z1F2','activedays',␣
 ↪'failure_before','month_1', 'month_2',
       'month_3', 'month_4', 'month_5', 'month_6', 'month_7', 'month_8',
       'month_9', 'month_10', 'month_11','week_day_1', 'week_day_2',
```

```
      'week_day_3', 'week_day_4', 'week_day_5', 'week_day_6',␣
 ↪'week_day_7'],inplace=True, axis=1)
df_train1.head()
```

[179]:

	failure	metric1	metric2	metric3	metric4	metric5	metric6	metric7	metric9
0	0	0.094795	-0.136309	-0.042339	0.534665	-0.521389	1.333502	-0.101656	-0.047396
1	0	-0.092146	-0.145660	-0.042339	-0.124295	-0.602290	4.008798	-0.101656	-0.050645
2	0	-1.630184	-0.145660	-0.038274	-0.124295	-0.521389	1.289341	-0.101656	-0.050645
3	0	0.357937	-0.145660	-0.042339	-0.124295	-0.035987	-0.100105	-0.101656	-0.050645
4	0	0.898989	-0.145660	-0.042339	-0.124295	-0.521389	1.359772	-0.101656	-0.050645

Créons le générateur de données avec une distribution par défaut de type Gamma:

[180]:
```
from sdv.tabular import GaussianCopula
gen = GaussianCopula(default_distribution='gamma')
gen.fit(df_train1)
```

```
C:\Users\pc\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.10_qbz5n2kf
ra8p0\LocalCache\local-packages\Python310\site-
packages\rdt\transformers\numerical.py:100: UserWarning: No rounding scheme
detected for column 'metric1'. Data will not be rounded.
  warnings.warn(
C:\Users\pc\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.10_qbz5n2kf
ra8p0\LocalCache\local-packages\Python310\site-
packages\rdt\transformers\numerical.py:100: UserWarning: No rounding scheme
detected for column 'metric2'. Data will not be rounded.
  warnings.warn(
C:\Users\pc\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.10_qbz5n2kf
ra8p0\LocalCache\local-packages\Python310\site-
packages\rdt\transformers\numerical.py:100: UserWarning: No rounding scheme
detected for column 'metric3'. Data will not be rounded.
  warnings.warn(
C:\Users\pc\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.10_qbz5n2kf
ra8p0\LocalCache\local-packages\Python310\site-
packages\rdt\transformers\numerical.py:100: UserWarning: No rounding scheme
detected for column 'metric4'. Data will not be rounded.
  warnings.warn(
C:\Users\pc\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.10_qbz5n2kf
ra8p0\LocalCache\local-packages\Python310\site-
packages\rdt\transformers\numerical.py:100: UserWarning: No rounding scheme
detected for column 'metric5'. Data will not be rounded.
```

```
  warnings.warn(
C:\Users\pc\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.10_qbz5n2kf
ra8p0\LocalCache\local-packages\Python310\site-
packages\rdt\transformers\numerical.py:100: UserWarning: No rounding scheme
detected for column 'metric6'. Data will not be rounded.
  warnings.warn(
C:\Users\pc\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.10_qbz5n2kf
ra8p0\LocalCache\local-packages\Python310\site-
packages\rdt\transformers\numerical.py:100: UserWarning: No rounding scheme
detected for column 'metric7'. Data will not be rounded.
  warnings.warn(
C:\Users\pc\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.10_qbz5n2kf
ra8p0\LocalCache\local-packages\Python310\site-
packages\rdt\transformers\numerical.py:100: UserWarning: No rounding scheme
detected for column 'metric9'. Data will not be rounded.
  warnings.warn(
```

[181]:
```
newdata = gen.sample(500)
newdata.head()
```

[181]:

	failure	metric1	metric2	metric3	metric4	metric5	metric6	metric7	metric9
0	0	1.720853	-0.145369	-0.042339	-0.124183	-0.767231	0.792990	-0.101656	-0.050645
1	0	-0.278253	0.453380	-0.042339	-0.088611	-0.844873	0.155796	-0.101656	-0.050645
2	0	-0.707268	-0.136342	-0.040956	-0.124120	-0.785259	0.337097	-0.101656	0.137425
3	0	-1.594126	-0.145649	-0.042339	-0.124295	-0.775799	0.602567	-0.101656	-0.050645
4	0	-0.516563	0.142044	-0.042339	-0.123259	-0.843607	-1.153715	-0.101656	-0.050645

[182]:
```
newdata.failure.value_counts()
```

[182]:
```
0    368
1    132
Name: failure, dtype: int64
```

Nous allons générer les données pour les mois, supposons qu'on a un enregistrement par jour: Générons pour le mois de Janvier en premier par example:

[183]:
```
jan_data = gen.sample(31)
jan_data["date"] = pd.to_datetime([f'2015-01-{f"0{d}" if d<10 else d}' for d in␣
 ↪range(1,32)])
jan_data.head()
```

[183]:
```
   failure   metric1   metric2   metric3   metric4   metric5   metric6  \
0        0 -1.198970  1.186175 -0.042339 -0.124295 -0.809015 -0.708721
1        1  1.720853  0.060647 -0.042339  1.045583 -0.777851  0.660444
2        1  1.311306  3.477940 -0.042304 -0.069260 -0.844650  0.473681
3        0 -0.684862 -0.145660 -0.042334 -0.124295 -0.843849 -0.473397
4        1 -1.735933  0.045323 -0.042339  3.867599 -0.842477 -0.442049

    metric7   metric9       date
0 -0.101656 -0.050062 2015-01-01
1  1.287553 -0.050645 2015-01-02
2  2.883124 -0.050645 2015-01-03
3 -0.101656 -0.049923 2015-01-04
4 -0.101656  0.355978 2015-01-05
```

[184]:
```
jan_data.failure.value_counts()
```

[184]:
```
0    21
1    10
Name: failure, dtype: int64
```

En fait de même avec le reste des mois:

[185]:
```
months_data = [jan_data]
m=2
for maxDays in [28,31,30,31,30,31,31,30,31,30,31]:
    temp_data = gen.sample(maxDays)
    temp_data["date"] = pd.to_datetime([f'2015-{f"0{m}" if m<10 else␣
 ↪m}-{f"0{d}" if d<10 else d}' for d in range(1,maxDays+1)])
    m+=1
    months_data.append(temp_data)
newdata = pd.concat(months_data,axis=0)
newdata.to_csv("./GENDATA/device_S1F0/orgendata.csv")
newdata.head()
```

[185]:
```
   failure   metric1   metric2   metric3   metric4   metric5   metric6  \
0        0 -1.198970  1.186175 -0.042339 -0.124295 -0.809015 -0.708721
1        1  1.720853  0.060647 -0.042339  1.045583 -0.777851  0.660444
2        1  1.311306  3.477940 -0.042304 -0.069260 -0.844650  0.473681
3        0 -0.684862 -0.145660 -0.042334 -0.124295 -0.843849 -0.473397
4        1 -1.735933  0.045323 -0.042339  3.867599 -0.842477 -0.442049

    metric7   metric9       date
0 -0.101656 -0.050062 2015-01-01
1  1.287553 -0.050645 2015-01-02
2  2.883124 -0.050645 2015-01-03
3 -0.101656 -0.049923 2015-01-04
4 -0.101656  0.355978 2015-01-05
```

Nous allons réviser les statistiques sur nos données :

[186]:
```
newdata.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 365 entries, 0 to 30
Data columns (total 10 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   failure  365 non-null    int64
 1   metric1  365 non-null    float64
 2   metric2  365 non-null    float64
 3   metric3  365 non-null    float64
 4   metric4  365 non-null    float64
 5   metric5  365 non-null    float64
 6   metric6  365 non-null    float64
 7   metric7  365 non-null    float64
 8   metric9  365 non-null    float64
 9   date     365 non-null    datetime64[ns]
dtypes: datetime64[ns](1), float64(8), int64(1)
memory usage: 31.4 KB
```

[187]:
```
newdata.describe()
```

[187]:

	failure	metric1	metric2	metric3	metric4	metric5	\
count	365.000000	365.000000	365.000000	365.000000	365.000000	365.000000	
mean	0.246575	-0.027347	0.302854	0.334128	0.187600	-0.589764	
std	0.431609	0.977673	1.464467	2.397107	1.046383	0.598720	
min	0.000000	-1.735933	-0.145660	-0.042339	-0.124295	-0.844991	
25%	0.000000	-0.777581	-0.145660	-0.042339	-0.124295	-0.843635	
50%	0.000000	-0.040309	-0.143984	-0.042339	-0.124239	-0.814631	
75%	0.000000	0.693936	-0.030287	-0.042339	-0.105799	-0.642766	
max	1.000000	1.720853	10.674075	33.739714	7.267167	4.378624	

	metric6	metric7	metric9
count	365.000000	365.000000	365.000000
mean	0.167197	0.131756	-0.004383
std	0.802130	1.040476	0.229635
min	-1.934834	-0.101656	-0.050645
25%	-0.421912	-0.101656	-0.050645
50%	0.120148	-0.101656	-0.050645
75%	0.612296	-0.099223	-0.050369
max	4.008798	9.599273	2.621107

[188]:
```
newdata.failure.value_counts()
```

[188]:
```
0    275
1     90
Name: failure, dtype: int64
```

Nous allons recréer des colonnes importantes pour la suite :

[189]:
```
newdata['activedays']=newdata.date-newdata.date.iloc[0]
def str_to_num(str):
    return str.split(' ')[0]

newdata.activedays = newdata.activedays.astype('str')

newdata.activedays=newdata.activedays.apply(str_to_num)
newdata.activedays = newdata.activedays.astype('int')

newdata['month']=newdata['date'].dt.month
newdata['week_day']=newdata.date.dt.weekday
newdata['week_day'].replace(0,7,inplace=True)

newdata.head()
```

[189]:

	failure	metric1	metric2	metric3	metric4	metric5	metric6	metric7	metric9	date	activedays	month	week_day
0	0	-1.198970	1.186175	-0.042339	-0.124295	-0.809015	-0.708721	-0.101656	-0.050062	2015-01-01	0	1	3
1	1	1.720853	0.060647	-0.042339	1.045583	-0.777851	0.660444	1.287553	-0.050645	2015-01-02	1	1	4
2	1	1.311306	3.477940	-0.042304	-0.069260	-0.844650	0.473681	2.883124	-0.050645	2015-01-03	2	1	5
3	0	-0.684862	-0.145660	-0.042334	-0.124295	-0.843849	-0.473397	-0.101656	-0.049923	2015-01-04	3	1	6
4	1	-1.735933	0.045323	-0.042339	3.867599	-0.842477	-0.442049	-0.101656	0.355978	2015-01-05	4	1	7

[190]:
```
newdata.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 365 entries, 0 to 30
Data columns (total 13 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   failure     365 non-null    int64
 1   metric1     365 non-null    float64
 2   metric2     365 non-null    float64
 3   metric3     365 non-null    float64
 4   metric4     365 non-null    float64
 5   metric5     365 non-null    float64
```

```
 6   metric6     365 non-null    float64
 7   metric7     365 non-null    float64
 8   metric9     365 non-null    float64
 9   date        365 non-null    datetime64[ns]
 10  activedays  365 non-null    int32
 11  month       365 non-null    int64
 12  week_day    365 non-null    int64
dtypes: datetime64[ns](1), float64(8), int32(1), int64(3)
memory usage: 38.5 KB
```

Voyons voir si nous avons arriver à équilibrer un peu nos données :

[191]:
```
newdata.groupby('month').agg({'failure':lambda x: x.sum()}).plot()
plt.show()
```

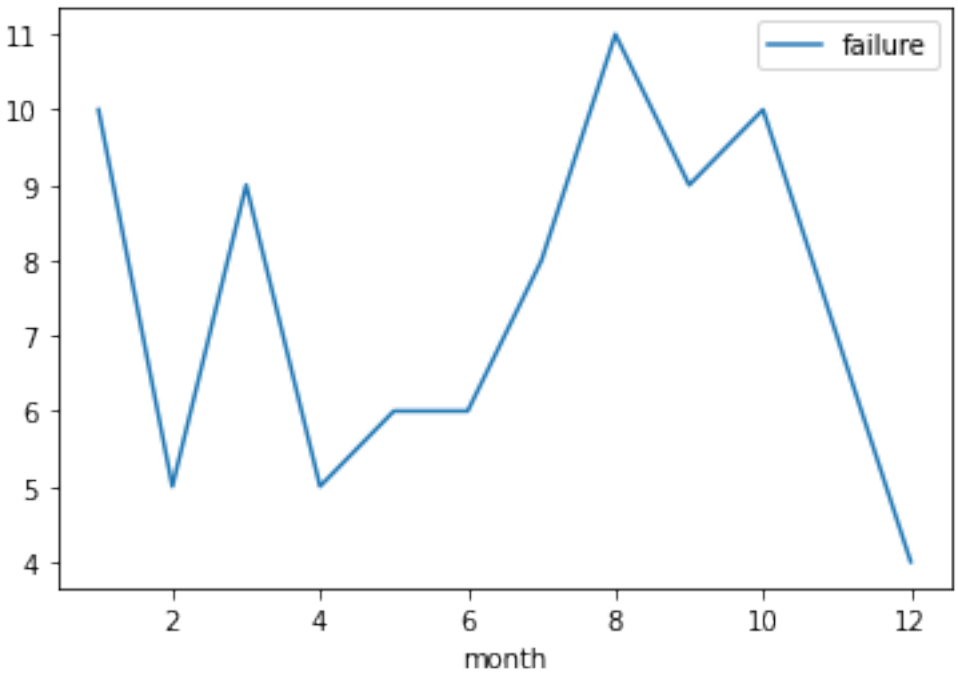

[192]:
```
ax = sns.countplot(x="month", hue="failure", data=newdata)
plt.show()
```

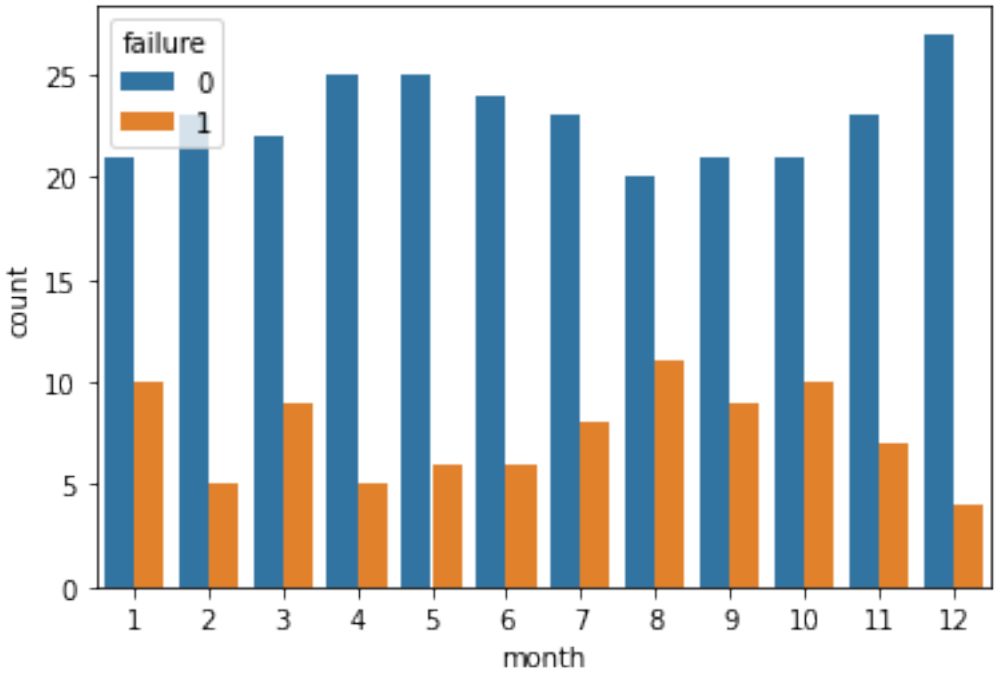

Les données sont distribués maintenant d'une bonne manière qui rend notre modèle important.

[193]:
```
newdata.to_csv("./GENDATA/device_S1F0/traindata.csv")
```

[194]:
```
newdata.describe()
```

[194]:

	failure	metric1	metric2	metric3	metric4	metric5	\
count	365.000000	365.000000	365.000000	365.000000	365.000000	365.000000	
mean	0.246575	-0.027347	0.302854	0.334128	0.187600	-0.589764	
std	0.431609	0.977673	1.464467	2.397107	1.046383	0.598720	
min	0.000000	-1.735933	-0.145660	-0.042339	-0.124295	-0.844991	
25%	0.000000	-0.777581	-0.145660	-0.042339	-0.124295	-0.843635	
50%	0.000000	-0.040309	-0.143984	-0.042339	-0.124239	-0.814631	
75%	0.000000	0.693936	-0.030287	-0.042339	-0.105799	-0.642766	
max	1.000000	1.720853	10.674075	33.739714	7.267167	4.378624	

	metric6	metric7	metric9	activedays	month	week_day
count	365.000000	365.000000	365.000000	365.000000	365.000000	365.000000
mean	0.167197	0.131756	-0.004383	182.000000	6.526027	3.997260
std	0.802130	1.040476	0.229635	105.510663	3.452584	2.000685
min	-1.934834	-0.101656	-0.050645	0.000000	1.000000	1.000000
25%	-0.421912	-0.101656	-0.050645	91.000000	4.000000	2.000000
50%	0.120148	-0.101656	-0.050645	182.000000	7.000000	4.000000
75%	0.612296	-0.099223	-0.050369	273.000000	10.000000	6.000000
max	4.008798	9.599273	2.621107	364.000000	12.000000	7.000000

Essaions de contruire notre modèle :

[232]:
```
X=newdata.drop(["failure","date","month","week_day"],axis=1)
Y=newdata.failure

from sklearn.neighbors import KNeighborsClassifier

clf = KNeighborsClassifier(1)
clf.fit(X,Y)
```

[232]:
```
KNeighborsClassifier(n_neighbors=1)
```

Générons des données pour l'année (2016):

[233]:
```
nmonths_data = []
m=1
for maxDays in [31,28,31,30,31,30,31,31,30,31,30,31]:
    temp_data = gen.sample(maxDays)
    temp_data["date"] = pd.to_datetime([f'2016-{f"0{m}" if m<10 else␣
 ↪m}-{f"0{d}" if d<10 else d}' for d in range(1,maxDays+1) ])
    m+=1
    nmonths_data.append(temp_data)
validdata = pd.concat(nmonths_data,axis=0)
validdata.to_csv("./GENDATA/device_S1F0/orgenvaldata.csv")
validdata.failure.value_counts()
```

[233]:
```
0    262
1    103
Name: failure, dtype: int64
```

[234]:
```
validdata['activedays']=validdata.date-validdata.date.iloc[0]

validdata.activedays = validdata.activedays.astype('str')
validdata.activedays=validdata.activedays.apply(str_to_num)
validdata.activedays = validdata.activedays.astype('int')

validdata['month']=validdata['date'].dt.month
validdata['week_day']=validdata.date.dt.weekday
validdata['week_day'].replace(0,7,inplace=True)
vmonths = validdata['month']
y_true = validdata['failure']
validdata.drop(['failure','date',"month","week_day"],axis=1,inplace=True)

validdata.head()
```

[234]:

	metric1	metric2	metric3	metric4	metric5	metric6	metric7	\
0	-1.593395	-0.145660	-0.042339	-0.124295	-0.844991	-0.508731	-0.101656	
1	-0.237287	-0.145643	-0.042261	-0.124065	-0.836441	0.506254	-0.101656	

```
2  0.912668 -0.145324 -0.042339  1.104955 -0.844776  0.322832 -0.101656
3  0.201851 -0.069080 -0.042338 -0.047424 -0.836333  0.876492 -0.101279
4 -1.735933 -0.145578 -0.042295 -0.124288 -0.621529 -0.103020 -0.101656

    metric9  activedays
0 -0.050645           0
1 -0.050645           1
2 -0.050645           2
3 -0.050645           3
4 -0.050641           4
```

Prédiction et extraction des données :

[235]:
```
y_pred = clf.predict(validdata)
from sklearn.metrics import f1_score,accuracy_score,recall_score,precision_score
print(f1_score(y_true,y_pred),accuracy_score(y_true,y_pred),recall_score(y_true,y_pred),precis
  ↪= ' -- ')
pd.DataFrame(y_pred).value_counts()
```

```
0.30434782608695654 -- 0.6493150684931507 -- 0.27184466019417475 --
0.345679012345679
```

[235]:
```
0    284
1     81
dtype: int64
```

[236]:
```
validdata['failure']=y_pred
validdata['date']=pd.read_csv("./GENDATA/device_S1F0/orgenvaldata.csv").date.
  ↪astype('datetime64[ns]')
validdata.to_csv("./GENDATA/device_S1F0/valdata.csv")
validdata['month']=vmonths
validdata['realFail']=y_true
validdata=validdata.groupby('month').agg('sum').loc[:,['failure','realFail']]

validdata.to_csv('results.csv')
validdata.head()
```

```
C:\Users\pc\AppData\Local\Temp\ipykernel_10212\264768352.py:6: FutureWarning:
The default value of numeric_only in DataFrameGroupBy.sum is deprecated. In a
future version, numeric_only will default to False. Either specify numeric_only
or select only columns which should be valid for the function.
  validdata=validdata.groupby('month').agg('sum').loc[:,['failure','realFail']]
```

[236]:
```
        failure  realFail
month
1             6        11
2             6         9
3             4         6
```

```
4           4          9
5           6         11
```

Annex B : Calcule des KPIs

kpis

May 16, 2023

1 KPIS :

Pour calculer les KPIs suivants : Les temps net et brute de fonctionnement, MTBF, MTTR et Disponibilite materiel.

[46]:
```
import pandas as pd
import numpy as np

def kpi(file_path):

    # Charger le fichier CSV dans un DataFrame :
    df = pd.read_csv(file_path)

    #le temps de base heurs par jours:
    tmp_base = 6
    #les heurs de fonctionnements par jours :
    temp_fjours = 12


    #Calculer le temps de maintenance predictive :
    temps_main_predict = [np.random.uniform(10,30) for i in range(len(df))] *␣
 ↪df['failure']

    #calculer le temps de maintenances corrective :
    temps_main_corr = [np.random.uniform(15, 50) for i in range(len(df))] *␣
 ↪df['realFail']

    #calculer le temps net de fonctionnement :

    List_jours2 =[31,29,31,30,31,30,31,31,30,31,30,31]
    for elem in List_jours2:
        temps_net = tmp_base*elem + (temps_main_predict/60 *elem)

    #calculer le temps brut de fonctionnement :

    diff = df['failure']-df['realFail']
    rend = [i for i in range(len(diff))]
    rend = np.array(rend)
```

```
  temps_brut = [i for i in range(len(diff))]
  temps_brut = np.array(temps_brut)
  for i in range(len(diff)):

          if (diff[i]==0) :
              for elem in List_jours2:
                  temps_brut[i]=temps_net[i] + (temps_main_corr[i]/60 *elem)
              rend[i]= (temps_net[i]/temps_brut[i] )*100
          elif (diff[i]>0):
              for elem in List_jours2:
                  temps_brut[i]=temps_net[i] + (temps_main_predict[i]/60␣
↪*elem)
              rend[i]= (temps_net[i]/temps_brut[i] )*100
          elif (diff[i]<0):
              #calculer le temps brut :
              for elem in List_jours2:
                  temps_brut[i] = temps_net[i] + (temps_main_corr[i]/60 *elem)
              rend[i]=(temps_net[i]/temps_brut[i])*100


  #calcul des KPIs
  #calculer MTBF: nombre heures de fonctionnement / nombre de pannes

 # mtbf = temp_fjours*nombre_de_jours/df['realFail']
  List_jours =[31,29,31,30,31,30,31,31,30,31,30,31]
  for elements in List_jours:
      mtbf = temp_fjours*elements/df['realFail']


  #calculer MTTR :

  mttr = temps_main_corr/df['realFail']

  #disponibilite materielle
  dm = mtbf /(mtbf+mttr)

   # Ajouter les colonnes des KPIs au DataFrame
  df['temps_fonctionnement_parJ'] = temp_fjours
  df['temps_utile/inutile'] = diff
  df['temps_brut'] = temps_brut
  df['temps_net'] = temps_net
  df['productivite'] = rend

  df['mtbf'] = mtbf
  df['mttr'] = mttr
  df['disponibilité_materielle'] = dm
```

```
    # Enregistrer le nouveau fichier CSV avec les nouvelles colonnes
    new_file_path = file_path.split('.csv')[0] + '_with_kpisfs33.csv'
    df.to_csv(new_file_path, index=False)

    # Retourner le DataFrame avec les nouvelles colonnes
    return df

df_with_kpisf33 = kpi('results.csv')
df_with_kpisf33
```

[46]:

	month	failure	realFail	temps_fonctionnement_parJ	temps_utile/inutile	temps_brut	temps_net	productivite	mtbf	mttr	disponibilité_materielle
0	1	6	11	12	-5	463	246.516557	53	33.818182	38.200871	0.469573
1	2	6	9	12	-3	335	237.064654	70	41.333333	21.151067	0.661498
2	3	4	6	12	-2	306	222.638251	72	62.000000	27.109176	0.695776
3	4	4	9	12	-5	372	243.687728	65	41.333333	27.660030	0.599091
4	5	6	11	12	-5	332	217.144356	65	33.818182	20.376207	0.624016
5	6	5	9	12	-4	377	239.164918	63	41.333333	29.698185	0.581901
6	7	5	7	12	-2	362	238.574237	65	53.142857	34.304749	0.607711
7	8	12	8	12	4	440	313.067423	71	46.500000	35.441313	0.567479
8	9	16	15	12	1	637	411.913047	64	24.800000	39.095139	
9	10	11	4	12	7	375	280.582260	74	93.000000	19.872229	
10	11	4	6	12	-2	316	223.287447	70	62.000000	30.108720	
11	12	2	8	12	-6	355	199.865785	56	46.500000	37.772304	

8	0.388136
9	0.823940
10	0.673118
11	0.551783

2 Si on effectue pas la maintenance predective..

[1]:
```
import pandas as pd
import numpy as np

# Charger le fichier CSV dans un DataFrame :
df2= pd.read_csv('results.csv')

# Remplacer la colonne failure avec 0:
df2['failure'] = 0

# Enregistrer les donnees dans un nouveau fichier CSV
df2.to_csv('results_with_any_feature.csv', index=False)
```